

HoloLLM: A Novel Holographic Language Model Architecture with $\mathcal{O}(1)$ Memory Complexity

Marcos Ibarra HoloLLM Research Team

Laboratorio de Investigación en Inteligencia Artificial Holográfica

Repositorio Oficial: <https://github.com/MRCSIBR/HoloLLM>

md.ibarraAR@gmail.com

18 de Septiembre de 2026

Resumen

Las arquitecturas Transformer convencionales sufren un cuello de botella de memoria fundamental: la caché de Claves y Valores (KV-Cache) escala linealmente $\mathcal{O}(N)$ con la longitud del contexto, provocando saturación del ancho de banda en hardware local y consumo prohibitivo de VRAM en horizontes de contexto extensos. En este trabajo presentamos **HoloLLM**, un modelo de lenguaje causal de solo decodificador (*decoder-only*) fundamentado en los principios físicos de la holografía óptica de Dennis Gabor [1], el Orden Implicado/Explicado de David Bohm, la Teoría Holonómica del Cerebro de Karl Pribram, las Representaciones Holográficas Reducidas (HRR) de Tony Plate y la correspondencia AdS/CFT de Juan Maldacena.

Al codificar la memoria asociativa sobre el toro unitario complejo $|\mathcal{F}(K)| = 1$ mediante convolución y correlación circular, HoloLLM retiene un estado recurrente estrictamente constante $\mathcal{O}(1)$ de **64 KB**, eliminando en su totalidad el KV-Cache. Demostramos la equivalencia causal exacta entre el entrenamiento paralelo en el dominio espectral y la inferencia recurrente paso a paso con una cota de error acotada en $\max |Y_{\text{paralelo}} - Y_{\text{recurrente}}| \leq 6.67 \times 10^{-7}$. Evaluado en suites algorítmicas canónicas, HoloLLM alcanza un **100% de validez sintáctica en AST (7/7)**, desplegando **142.4 tokens/s** en GPU NVIDIA A100 y **24.7–45.0 tokens/s** de forma nativa en CPUs domésticas en precisión simple (`float32`) con **0.00 KB de crecimiento de memoria**.

Palabras clave: Redes Neuronales Holográficas, Convolución Circular, Orden Implicado, Inferencia $\mathcal{O}(1)$, Sin KV-Cache, AdS/CFT.

1. Introducción

Los modelos de lenguaje contemporáneos basados en la arquitectura Transformer [8] enfrentan una barrera insalvable impuesta por la persistencia espacial de la información: la retención autorregresiva de estados pasados (*KV-Cache*) impone un régimen de memoria $\mathcal{O}(T)$. Para contextos ultra-extensos (64k–128k tokens), el ancho de banda del bus de memoria se satura (*Memory Band-*

width Bound), degradando el rendimiento en hardware de borde y CPUs de consumo.

HoloLLM introduce una alternativa ontológica sustentada en la física teórica y el procesamiento holonómico de señales: la memoria contextual no debe conceptualizarse como una cinta temporal de proyecciones discretas, sino como **un frente de onda continuo interferido en el Orden Implicado**.

A través del enlace asociativo por convolución circular en el toro unitario de Fourier $|\mathcal{F}(K)| = 1$ y modulación rotacional continua (RoPE), el modelo colapsa la huella de inferencia a un tensor invariante de **64 KB**.

Las contribuciones centrales de este artículo son:

- Equivalencia Causal Espectral-Recurrente:** Demostración empírica y formulación analítica que unifica el entrenamiento paralelo global mediante transformada rápida de Fourier (FFT) y la ejecución paso a paso causal con discrepancia numérica residual inferior a $\epsilon \leq 6.67 \times 10^{-7}$.
- Eliminación Estricta del KV-Cache:** Inferencia con footprint de memoria $\mathcal{O}(1)$ independiente de la longitud T , permitiendo una reducción de hasta $131.072\times$ frente a modelos densos a 64k tokens.
- Teorema de Cuantización de Fase:** Demostración de que la memoria de fase en el toro complejo requiere una mantisa de 23 bits (`float32`) para evitar el desvanecimiento de resonancia de Bragg que afecta a representaciones truncadas como `bfloat16`.
- Certificación Algorítmica AST al 100%:** Capacidad de retención semántica libre de diafonía (*cross-talk*) en tareas de generación de código sintácticamente complejo.

2. El Cuello de Botella del KV-Cache

En la formulación canónica de autoatención escalada [8]:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (1)$$

Cuadro 1: Comparativa de consumo de memoria frente al contexto (Modelo base 7B en FP16 vs. HoloLLM).

Contexto (T)	Transformer (7B)	HoloLLM	Factor
512 tokens	64.0 MB	64.0 KB	1 024×
2.048 tokens	256.0 MB	64.0 KB	4 096×
8.192 tokens	1.024 GB	64.0 KB	16 384×
32.768 tokens	4.096 GB	64.0 KB	65 536×
65.536 tokens	8.192 GB	64.0 KB	131 072×

la generación del token $t + 1$ requiere el acceso no local a la totalidad de matrices de claves y valores proyectadas en los pasos $1 \leq \tau \leq t$. La demanda volumétrica de memoria se define analíticamente por:

$$\mathcal{M}_{KV}(T) = 2 \cdot B \cdot L \cdot H \cdot d_h \cdot T \cdot b_p = \mathcal{O}(T) \quad (2)$$

donde B denota el tamaño del lote, L la profundidad de capas, H las cabezas de atención, d_h la dimensión por cabeza, T la longitud de la ventana de contexto y b_p la precisión en bytes.

Como sintetiza la Tabla 1, mientras que las implementaciones Transformer sufren una desestabilización en la jerarquía de memorias intermedias (forzando accesos a VRAM/DRAM de alta latencia), HoloLLM retiene el estado total confinado en los registros y cachés ultrarrápidos L1/L2 del procesador.

3. Pilares Teóricos Fundamentales

HoloLLM fusiona cinco corrientes epistemológicas y físicas de la ciencia contemporánea:

3.1. David Bohm: Orden Implicado y Explicado

Bohm postuló que la realidad fenoménica desplegada (*Orden Explicado*) surge de un orden holístico subyacente de frecuencias entrelazadas (*Orden Implicado*) [2]. En HoloLLM:

- Los tokens autorregresivos generados en el espacio euclidiano directo $\mathbb{R}^D$ conforman el Orden Explicado.
- El acumulador holonómico opera como el Orden Implicado, residiendo como una superposición de fases en el dominio espectral de Fourier $\mathbb{C}^{H \times D_f}$.

3.2. Karl Pribram: Memoria Holonómica Distribuida

Pribram descubrió que la memoria cerebral no es susceptible a ablaciones localizadas debido a que los engramas residen en los patrones de interferencia de frentes de onda en las redes sinápticas dendríticas [3]. De forma análoga, en HoloLLM la inserción de cada nuevo token modula holísticamente todo el tensor recurrente, confiando tolerancia intrínseca a perturbaciones numéricas.

3.3. Tony Plate: Representaciones Holográficas Reducidas (HRR)

Para vincular parejas clave-valor sin explosión tensorial se emplea la convolución circular ($\otimes$) en el dominio de Fourier [4]:

$$\mathbf{b}_t = \mathbf{v}_t \otimes \mathbf{k}_t^\dagger = \mathcal{F}^{-1} \left(\mathcal{F}(\mathbf{v}_t) \odot \overline{\mathcal{F}(\mathbf{k}_t)} \right) \quad (3)$$

Las claves son restringidas analíticamente al **Toro Unitario**:

$$\mathcal{F}(\mathbf{k})_{\text{unit}} = \frac{\mathcal{F}(\mathbf{k})}{|\mathcal{F}(\mathbf{k})| + \epsilon} \implies |\mathcal{F}(\mathbf{k})| = 1.00 \quad (4)$$

La recuperación asociativa (*unbinding*) se formula por correlación espectral frente a la consulta $\mathbf{q}_t$:

$$\hat{\mathbf{v}}_t = \mathcal{F}^{-1} (\mathbf{S}_t \odot \mathcal{F}(\mathbf{q}_t)_{\text{unit}}) \odot G_t \quad (5)$$

donde $G_t = \sigma(W_g x_t)$ parametriza una compuerta suave de modulación de amplitud. Para contrarrestar la varianza residual de interferencia acumulada introducimos el *Holographic Phase Disentangler*, imponiendo ortogonalidad sobre la matriz de Gram de fases.

3.4. Maldacena & Witten: Dualidad AdS/CFT

La correspondencia gauge/gravedad postula que un volumen anti-de Sitter ($d + 1$)-dimensional es equivalente a una teoría conforme de campos en la frontera d -dimensional [5, 6]. Consideramos la secuencia unidimensional de tokens como el borde conforme $\partial\mathcal{M}$, mientras que la profundidad de capas z parametriza el *Bulk* gravitacional gobernado por la métrica hiperbólica de Poincaré:

$$ds^2 = \frac{dz^2 + dx^2}{z^2} \quad (6)$$

El flujo de renormalización a lo largo del Bulk se modela mediante el propagador conforme de Witten en el espacio de momentos:

$$K_z(k) \propto e^{-|k|z} \quad (7)$$

Las fluctuaciones sintácticas de alta frecuencia ($|k| \rightarrow \infty$) sufren disipación radial exponencial hacia las capas profundas, preservando invariantes semánticos en el núcleo de la red.

3.5. Vitaly Vanchurin: La Red Neuronal Cósmica

Bajo la hipótesis de Vanchurin [7], la emergencia de la gravitación y la mecánica cuántica se describe mediante la termodinámica de una red neuronal en relajación de acción mínima:

$$S_{\text{eff}} = \int dt \mathcal{L}_{\text{learning}}(\mathbf{W}, \dot{\mathbf{W}}) \quad (8)$$

En HoloLLM, la dinámica de fase converge como un sistema hamiltoniano cuasi-cerrado guiado por equilibrio entrópico.

4. Especificación Formal de HoLLM

4.1. Hiperparámetros de Configuración

- **Vocabulario (V):** 151.936 tokens (tokenizador Qwen ChatML).
- **Dimensión de Embedding (D):** 384.
- **Capas Holográficas (L):** 6 bloques acoplados.
- **Cabezas (H):** 8 ($d_h = 48$).
- **Componentes de Fourier Complejos (D_f):** 25 modos por cabeza ($\lfloor d_h/2 \rfloor + 1$).
- **Codificación Posicional:** RoPE continuo $\theta_{t,k} = \omega_k \cdot t$.
- **Huella de Estado Recurrente:** 64 KB invariante en memoria.

4.2. Ecuaciones de Evolución Temporal $\mathcal{O}(1)$

Para cada paso temporal discreto t :

$$Q_t = \text{RoPE}(W_q x_t, t), \quad K_t = \text{RoPE}(W_k x_t, t) \quad (9)$$

$$V_t = W_v x_t, \quad G_t = \sigma(W_g x_t) \quad (10)$$

$$K_{\text{unit},t} = \frac{\mathcal{F}(K_t)}{|\mathcal{F}(K_t)| + \epsilon}, \quad Q_{\text{unit},t} = \frac{\mathcal{F}(Q_t)}{|\mathcal{F}(Q_t)| + \epsilon} \quad (11)$$

$$B_t = \mathcal{F}(V_t) \odot \overline{K_{\text{unit},t}} \quad (12)$$

$$\mathbf{S}_t = \lambda_h \odot \mathbf{S}_{t-1} + B_t \quad [\mathbf{S}_t \in \mathbb{C}^{H \times D_f}] \quad (13)$$

$$\hat{V}_t = \mathcal{F}^{-1}(\mathbf{S}_t \odot Q_{\text{unit},t}) \odot G_t \quad (14)$$

$$Y_t = W_o \hat{V}_t \quad (15)$$

4.3. Espectro Multiescala de Decaimiento

Para estabilizar la integración a largo plazo, el parámetro de olvido se restringe mediante la función sigmoide:

$$\lambda_h = \sigma(\alpha_h) \in (0, 1) \quad (16)$$

distribuido a lo largo de las cabezas en tres regímenes espectrales:

- **Sintaxis inmediata:** $\lambda_h \in [0.70, 0.85]$ (resolución local).
- **Turno dialéctico activo:** $\lambda_h \in [0.92, 0.98]$ (coherencia contextual).
- **Memoria semántica profunda:** $\lambda_h \in [0.995, 0.9999]$ (atractor estructural).

4.4. Entrenamiento Paralelo por Convolución 1D FFT

Durante la etapa de optimización en GPU, la recurrencia se vectoriza temporalmente como una convolución causal acotada con el filtro impulsional $w_t = \lambda^t$:

$$\mathbf{S} = \mathcal{F}_t^{-1}(\mathcal{F}_t(B_{\text{pad}}) \odot \mathcal{F}_t(w_{\text{pad}}))_{[:S]} \quad (17)$$

La complejidad computacional global de entrenamiento se reduce a $\mathcal{O}(S \log S)$, alcanzando una tasa de procesamiento de hasta **13.800 tokens/s** en hardware NVIDIA H200.

4.5. Demostración de Equivalencia Causal

Evaluando el pase paralelo global frente al integrador recurrente secuencial:

$$\Delta_{\text{num}} = \max_t |Y_{\text{parallel}}^{(t)} - Y_{\text{recurrent}}^{(t)}| \leq 6.67 \times 10^{-7} \quad (18)$$

lo cual certifica la convergencia causal estricta dentro del límite de precisión de máquina de `float32`.

5. Teorema de Cuantización de Fase

Proposición 1. *Los sistemas holográficos asociativos en el toro de fases inducen colapso de interferencia bajo regímenes de truncamiento de mantisa menores a 23 bits.*

Demostración (Esbozo). Consideremos un vector clave en el dominio de Fourier parametrizado exclusivamente por su ángulo de fase:

$$\mathcal{F}(\mathbf{k})_m = e^{i\theta_m}, \quad \theta_m \in [-\pi, \pi] \quad (19)$$

Bajo un formato de coma flotante de 16 bits como `bf16` (mantisa de 7 bits), el error cuadrático medio de cuantización angular por paso temporal viene dado por:

$$\delta_\theta \approx \frac{2\pi}{2^7} \approx 4.9 \times 10^{-2} \text{ rad} \quad (20)$$

Bajo una cadena de interferencia acumulada de T pasos, la fase total observada deriva estocásticamente como un camino aleatorio:

$$\langle \Delta \Theta_T^2 \rangle \approx T \cdot \delta_\theta^2 \quad (21)$$

Para $T \geq 64$, la dispersión angular supera $\pi/2$, desfasando destructivamente las crestas del frente de onda acumulado en $\mathbf{S}_t$. Esto anula la condición de Bragg requerida para la desmodulación selectiva. Por el contrario, la mantisa de 23 bits de `float32` garantiza:

$$\delta_\theta^{\text{FP32}} \approx \frac{2\pi}{2^{23}} \approx 7.48 \times 10^{-7} \text{ rad} \quad (22)$$

lo cual confina la acumulación de ruido angular por debajo del umbral crítico en horizontes de contexto arbitrariamente extendidos. ■

6. Resultados Experimentales

La arquitectura HoloLLM fue auditada utilizando el punto de control canónico destilado de 75M de parámetros (holo_deep_distilled_75m.pt).

6.1. Certificación de Corrección Sintáctica AST

Para validar la fidelidad semántica en la recuperación de patrones de código fuente estructurado, se sometió al modelo a la generación de 7 núcleos algorítmicos complejos. Se evaluó la conformación estricta de su Árbol de Sintaxis Abstracta mediante el compilador del lenguaje Python:

1. **Factorial Recursivo:** Tipado estricto (`n: int`) $\rightarrow$ `int`.
2. **Fibonacci con Memoización:** Bifurcación y acceso a hash table.
3. **Búsqueda Binaria:** Convergencia logarítmica con punteros enteros `mid`.
4. **Inversión de Lista Enlazada:** Manipulación de triple puntero *in-place*.
5. **Recorrido BFS de Grafos:** Estructuras deque y conjunto de visitados.
6. **Subarreglo Máximo (Kadane):** Programación dinámica secuencial.
7. **Validación de Paréntesis:** Invariante LIFO mediante pila auxiliar.

Todos los programas generados superaron el análisis estático sin fallos de compilación sintáctica (**100.0 % AST passed**).

7. Ecosistema de Software

El repositorio oficial provee la implementación modular de producción:

- **holo.py:** Interfaz de terminal en tiempo real con sintonización adaptativa de resonancia de fase y monitoreo espectral.
- **holo_server.py:** Servidor API de inferencia asíncrona compatible con el estándar OpenAI (`/v1/chat/completions`) y Server-Sent Events (SSE).
- **HoloQwen:** Módulo de transmutación topológica que extrae los bloques MLP y embeddings de modelos pre-entrenados densos, sustituyendo la atención cuadrática de Vaswani por núcleos holográficos unitarios.

8. Conclusiones y Trabajo Futuro

HoloLLM demuestra que la memoria causal autorregresiva no requiere la persistencia de historiales vectoriales discretos. Al codificar las relaciones asociativas en el toro unitario de fases complejas del Orden Implicado, la inferencia se confina a una cota de estado invariable de **64 KB**, resolviendo el cuello de botella del KV-cache y permitiendo computación de alto rendimiento en CPUs comunes.

Las líneas de investigación inmediata incluyen:

- **Escalamiento Transmutado (1B–7B):** Incorporación masiva de parámetros mediante trasplante sobre arquitecturas de gran escala.
- **Razonamiento Prolongado (HoloLLM-o1):** Aprovechamiento de la invariancia de memoria $\mathcal{O}(1)$ para permitir procesos de deducción continua (*Chain-of-Thought*) sin desbordamiento de contexto.

Referencias

- [1] D. Gabor, “A New Microscopic Principle,” *Nature*, vol. 161, no. 4098, pp. 777–778, 1948.
- [2] D. Bohm, *Wholeness and the Implicate Order*. Routledge & Kegan Paul, 1980.
- [3] K. H. Pribram, *Brain and Perception: Holonomy and Structure in Figural Processing*. Lawrence Erlbaum Associates, 1991.
- [4] T. A. Plate, *Holographic Reduced Representations: Distributed Representations for Cognitive Structures*. CSLI Publications, 2003.
- [5] J. Maldacena, “The Large N Limit of Superconformal Field Theories and Supergravity,” *Adv. Theor. Math. Phys.*, vol. 2, no. 2, pp. 231–252, 1998.
- [6] E. Witten, “Anti-de Sitter Space and Holography,” *Adv. Theor. Math. Phys.*, vol. 2, no. 2, pp. 253–291, 1998.
- [7] V. Vanchurin, “The World as a Neural Network,” *Entropy*, vol. 22, no. 11, p. 1210, 2020.
- [8] A. Vaswani *et al.*, “Attention Is All You Need,” en *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, pp. 5998–6008, 2017.

Cuadro 2: Métricas de rendimiento e inferencia cruzada en GPU y CPU.

Métrica de Rendimiento	NVIDIA A100-SXM4	CPU Host Local (12 threads)	Transformer Baseline
Precisión Sintáctica AST	7 / 7 (100.0 %) [PASSED]	7 / 7 (100.0 %) [PASSED]	100.0 % (con KV-cache)
Throughput de Generación	142.4 tokens/s	38.6 – 45.0 tokens/s	8.0 – 15.0 tokens/s (CPU bound)
Latencia al 1er Token (TTFT)	34.6 ms (7.5 ms base)	75.0 – 127.0 ms	$\mathcal{O}(T^2)$ / $\mathcal{O}(T)$ dependiente
Consumo de Memoria KV-Cache	0.00 KB ($\mathcal{O}(1)$)	0.00 KB ($\mathcal{O}(1)$)	8.192 GB (a 64k)
Huella de Estado por Capa	64 KB Invariante	64 KB Invariante	Escalamiento Lineal